Universidade de São Paulo
Instituto de Matemática e Estatística
Bacharelado em Matemática Aplicada e Computacional

Modelo preditivo para o rendimento de Soja através do NDVI em transformações flexíveis de Fourier

Gustavo Bomfim da Mota Ducatti

Monografia Final

map 2429 — Trabalho de Formatura em Matemática Aplicada

Supervisor: Prof. Dr. André Luis Squarize

São Paulo
2025

O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)

Dedico esse trabalho à minha família, cujo apoio foi essencial durante toda a minha trajetória acadêmica. Obrigado por todas as nossas maneiras.

Resumo

Gustavo Bomfim da Mota Ducatti. **Modelo preditivo para o rendimento de Soja através do NDVI em transformações flexíveis de Fourier**. Monografia (Bacharelado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2025.

Após reforçar a premissa de que a produção de Soja nos municípios brasileiros é sensível ao clima, o presente documento descreve o desenvolvimento de um modelo preditivo de produtividade de Soja com uso de NDVI, precipitação e temperatura. Os dados de índice vegetativo (NDVI) serão provenientes da plataforma eMODIS da NASA, os dados de precipitação do conjunto de dados CHIRPS e temperatura da ERA5. A partir desses dados, será construído um painel que agrupa anualmente a nível municipal informações de NDVI médio mensal de outubro a março e precipitação total e temperatura máxima de outubro a fevereiro. Assim, através desse painel, serão desenvolvidos modelos que estimam, a partir dos dados agrupados, a produtividade anual de soja em 1000 municípios brasileiros. O modelo do estudo usa transformadas flexíveis de Fourier (FFT), flexibilizando a relação entre o NDVI e a produtividade para a não linearidade. O objetivo é realizar o comparativo da modelagem estatística com e sem a inclusão das transformadas, demonstrando que há melhor desempenho do modelo com a inclusão. O modelo FFT apresentará melhores resultados quando comparado ao modelo padrão de OLS, tanto estatisticamente, através de teste de hipótese, como em métricas de erros em predições e previsões fora da amostra.

Palavras-chave: Modelos preditivos. Tranformadas de Fourier. Produtividade de soja. NDVI.

Abstract

Gustavo Bomfim da Mota Ducatti. **Predictive model for soybean yield using NDVI in flexible Fourier transforms**. Capstone Project Report (Bachelor). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2025.

After reinforcing the premise that soybean production in Brazilian municipalities is sensitive to climate, this document describes the development of a predictive model for soybean productivity using NDVI, precipitation, and temperature. The vegetation index (NDVI) data will come from NASA's eMODIS platform, the precipitation data from the CHIRPS dataset, and the temperature data from ERA5. Based on this data, we will construct a panel that groups together, on an annual basis and at the municipal level, information on the average monthly NDVI from October to March and total precipitation and maximum temperature from October to February. Thus, through this panel, we will use models that estimate, from the grouped data, the annual soybean productivity in 1,000 Brazilian municipalities. The study model uses flexible Fourier transforms (FFT), making the relationship between NDVI and productivity more flexible for non-linearity. The objective is to compare statistical modeling with and without the inclusion of transforms, demonstrating that the model performs better with their inclusion. The FFT model will present better results when compared to the standard OLS model, both statistically, through hypothesis testing, and in metrics of errors in predictions and forecasts outside the sample.

Keywords: Forecast. Fourier transform. Soybean Yield. NDVI.

Lista de abreviaturas

IME	Instituto de Matemática e Estatística
USP	Universidade de São Paulo
CNA	Confederação da Agricultura e Pecuária do Brasil
CONAB	Companhia Nacional de Abastecimento
CEPEA	Centro de Estudos Avançados em Economia Aplicada
NDVI	Índice de vegetação por diferença normalizada (*Normalized Difference Vegetation Index*)
FFT	Transformadas flexíveis de Fourier
IBGE	Instituto Brasileiro de Geografia e Estatística
ECMWF	Centro Europeu de Previsões Meteorológicas a Médio Prazo
CHIRPS	*Climate Hazards Group Infrared Precipitation with Stations*
INMET	Instituto Nacional de Meteorologia
MODIS	*Moderate Resolution Imaging Spectroradiometer*
OLS	Método dos Mínimos Quadrados
RMSE	Raiz do Erro Quadrático Médio
MAE	Erro Absoluto Médio
RMSD	Raiz da Diferença Quadrática Média
MAD	Diferença Média Absoluta

Lista de figuras

1 Municípios selecionados. 7
2 Gráfico de dispersão e boxplot de temperatura máxima de outubro a fevereiro 8
3 Gráfico de dispersão e boxplot de precipitação total de outubro a fevereiro 9
4 Gráfico de dispersão e boxplot de NDVI médio de outubro a março . . . 9
5 Gráfico de linhas de NDVI médio de outubro a março 10
6 Resolução das variáveis de satélite. 10
7 Heatmap da matriz de correlação das principais variáveis 16
8 Visuais de comparação de satélite e estação metereológica para Uberlândia 17
9 Visuais de comparação de satélite e estação metereológica para Chapecó 17
10 Dispersão da precipitação total em Alto Taquari para satélite e estação meterológica 19
11 Distribuição geográfica da elasticidade estimada do modelo FFT para NDVI 23
12 Desempenho na predição em painel 26

Lista de tabelas

1 Linhas aleatórias do painel de dados utilizado nos modelos 11
2 Correlações entre as principais variáveis e produtividade a nível estadual 15
3 Cidades para comparativo entre satélite e estações meteorológicas. 17
4 Diferenças entre as diferentes fontes de dados de temperatura e precipitação 18
5 Estatísticas descritivas do painel de dados 19
6 Resultados gerais dos modelos 20
7 Elasticidades dos modelos 22

8 ANOVA aplicado nos modelos 24
9 Desempenho na predição fora de amostra 25
10 Comparativo dos três métodos de predição 26
11 Desempenho nas previsões temporais 27
12 Erro por estado na estimativa para 2025 28
13 Erro na previsão de 2025 28

Sumário

Introdução **1**
Contexto climático . . . 1
A soja no Brasil . . . 1
Modelos preditivos . . . 2
Índice de vegetação . . . 2
Tranformadas flexíveis de Fourier . . . 3
Aplicação no trabalho . . . 3

Objetivos **5**
Objetivos gerais . . . 5
Objetivos específicos . . . 5
NDVI e Soja . . . 5
Dados de satélite . . . 5
Contribuição do índice vegetativo . . . 5
Capacidade preditiva . . . 6

Metodologia **7**
Dados . . . 7
Municípios . . . 7
Produtividade . . . 7
Temperatura . . . 8
Precipitação . . . 8
Estações meteorológicas . . . 9
NDVI . . . 9
Painel de dados . . . 11
Regressão quadrática . . . 11
Tranformadas de Fourier . . . 12
O modelo . . . 12

Poder preditivo 13

Resultados **15**

As variáveis 15

Correlações 15

Satélites e Estações metereológicas 16

Visual 17

Diferença absoluta 18

Análise descritiva 19

Modelo FFT 20

Resumo 20

Elasticidade 21

Teste de hipótese 23

Predição fora da amostra 24

Previsões e o desempenho em 2025 27

Conclusões **29**

Referências **31**

Introdução

Contexto climático

O aumento na frequência de inundações urbanas, como no Rio Grande do Sul em maio de 2024, ondas extremas de calor ou frio, como na Europa em maio de 2025, o terceiro mês mais quente já registrado no continente, como relatado pela Copernicus Climate Change Service (C3S) (2025), e outros eventos climáticos extraordinários são grandes indicadores do potencial agravamento dos impactos dos riscos climáticos em nossa sociedade, sejam eles sociais ou econômicos.

A suma importância para a segurança alimentar do povo brasileiro, a participação de pelo menos 20% do PIB nacional em 2024, como afirma a Confederação da Agricultura e Pecuária do Brasil (CNA) (2025) e o fortalecimento da balança comercial internacional são grandes indicadores da relevância - e substancialidade - do mercado agropecuário no Brasil.

Entretanto, como afirmaram E. D. Assad e M. L. R. C. L. Assad (2024): "a agricultura é altamente dependente do clima, e assim, as mudanças do clima afetam a produtividade e os ganhos financeiros, colocando em risco as expectativas de crescimento". Por exemplo, em 2021 quando ocorreu uma seca severa na região sul do Brasil, a produtividade nacional de grãos reduziu em 11.762.800 toneladas ($\approx$ 15.06%). Além disso, no mercado de soja, cultura de maior importância econômica no Brasil, a redução foi de $19.631.500T$ ($\approx 45,62\%$), conforme dados da Companhia Nacional de Abastecimento (CONAB) (2025).

A soja no Brasil

De acordo com Ferreira *et al.* (2024) 11,65% da perda de produção agrícola se deram por eventos de seca nas últimas 5 décadas no Brasil. Em 2024, a produção de soja foi de 147.721.300T, o que representa em torno de 49,65% da produção total de grãos no Brasil. A um custo médio de R$141,9 por saca de 60kg, conforme reportado pela CEPEA – Centro de Estudos Avançados em Economia Aplicada (2025) em novembro de 2025, essa produção equivale a R$ 335,17 bilhões. Ainda assim, essa cultura é extremamente sensível a épocas de estiagem ou excesso de chuvas. Em 2021/22, por exemplo, no Rio Grande do Sul, a perda de produção foi superior a 50%.

Dessa forma, destaca-se a importância de conseguir inferir adequadamente a relação estatística de variáveis climáticas na produtividade dessa cultura. Para isso, diversas estratégias podem ser tomadas, sendo uma delas a construção de modelos preditivos que

explicam a produtividade da soja em determinadas regiões utilizando as variáveis climáticas durante o ciclo desde a plantação até a colheita da cultura como variáveis exógenas.

Modelos preditivos

As previsões de produtividade agrícola já são amplamente utilizadas por agentes públicos e privados pois, dentre tantos motivos, ajudam na descoberta de preços no mercado agrícola e apoiam decisões governamentais rápidas. Entretanto, grande parte da previsões tradicionais são baseadas em pesquisas que são relativamente caras e trabalhosas. Assim, destaca-se o uso crescente de sensoriamento remoto, com coleta e processamento de dados via satélite, para melhorar a acurácia dessas previsões.

O presente trabalho relata a adaptação para o contexto brasileiro de um artigo escrito por Xu e Katchova, 2019 que descreve o desenvolvimento de um modelo de predição de produtividade de soja nos Estados Unidos utilizando transformadas flexíveis de Fourier (FFT) aplicadas no NDVI, o índice de vegetação por diferença normalizada.

Índice de vegetação

O NDVI é uma medida de densidade de biomassa na superfície da Terra. Calculado através da refletância das faixas do espectro, esse índice consegue indicar a saúde da vegetação de determinado local. Seu valor varia entre -1 e 1, em que valores negativos indicam ausência de vegetação, como água ou neve, como afirma Ashraf e Nawaz (2015), valores próximos de 0 indicam natureza morta ou vegetação esparsa e valores próximos de 1 apontam natureza muito saudável.

$$NDVI = \frac{NIR - RED}{NIR + RED} \tag{1}$$

O NDVI é calculado usando a diferença entre a refletância do infravermelho próximo (NIR) e a refletância da luz vermelha (RED), dividida pela soma dos dois, segundo a fórmula descrita na equação 1. Plantas saudáveis possuem uma alta concentração de clorofila, que é extremamente eficiente em absorver a luz visível, como a faixa do vermelho (RED), pela realização da fotossíntese. Além disso, a estrutura das folhas é excelente em refletir intensamente a luz infravermelha próxima (NIR), como afirmam Muminov *et al.* (2016).

Por outro lado, a vegetação seca - e o solo - refletem mais luz vermelha do que a vegetação saudável e refletem menos luz infravermelha próxima em comparação. O resultado é que, nesse caso, os valores de NIR e RED ficam próximos, ou o RED pode até ser ligeiramente maior.

Considerando o exposto acima, o objetivo do trabalho é inferir se o uso desses dados, aplicados com a técnica das transformadas de Fourier, pode ajudar a prever a produtividade de soja. Afinal, por serem de sensoriamento remoto, validada certa precisão dos dados, eles independem da localização e do desenvolvimento econômico das regiões analisadas.

Tranformadas flexíveis de Fourier

Durante a estimativa da produtividade agrícola com variáveis climáticas, tradicionalmente, modelos utilizam dummies regionais e temporais para capturar heterogeneidade espacial e temporal. Essa inclusão capta a diferença na variável endógena entre as regiões e ao longo do tempo, porém, não capta como essa diferença varia pelas características de cada local e período.

Gallant, 1981 foi o primeiro a propor a forma flexível de Fourier para uma aproximação não viesada da função de produtividade, no qual provou sua validade matemática, como comentam Xu e Katchova, 2019. Cooper *et al.* (2017) aplicaram uma função FFT para estimar a relação entre produtividade agrícola e temperatura, abordagem base para a reaplicação por Xu e Katchova, 2019 para a função flexível de Fourier, modelo que será seguido nesse estudo.

Aplicação no trabalho

Neste trabalho serão testados dois modelos distintos: uma regressão quadrática utilizando as variáveis convencionais - temperatura e precipitação - e incluindo NDVI de forma linear; e uma regressão com a inclusão de transformadas flexíveis de Fourier para o índice vegetativo, flexibilizando a linearidade do modelo e possibilitando a captura de comportamentos cíclicos da natureza.

Na academia, esse tipo de entendimento pode levar à melhoria de modelos, aumentando eficácias com a inclusão correta de parâmetros. Além disso, o comparativo dos modelos revelarão não só a significância da inclusão das transformadas na regressão, mas também do NDVI em relação às variáveis tradicionais temperatura e precipitação.

Além disso, há relevância também para o mercado agropecuário, financeiro e securitário. Por exemplo, seguros paramétricos são produtos que dispensam a necessidade de avaliação de danos de um sinistro, pois a indenização é feita conforme o acionamento de um parâmetro, como cita Gasparetto (2024). De forma a ilustrar o conceito, um exemplo fictício de um seguro paramétrico para Soja para uma cooperativa agrícola poderia ser: em caso de 20mm de chuva durante 10 dias consecutivos na região de uma de suas fazendas, indenizaria-se um valor pré-acordado.

Esse tipo de seguro tem como premissa de modelagem que o parâmetro a ser acionado é altamente correlacionado com a ocorrência de perdas na área segurada, pois, caso contrário, poderão ocorrer muitos falsos positivos (indenizações sem perdas) e/ou falsos negativos (perdas sem indenizações). Assim, estudos que levam a evoluções nesse processo são benquistos pelo mercado.

Objetivos

Objetivos gerais

Este trabalho tem como objetivo geral desenvolver modelos preditivos para a produtividade de soja através do uso de variáveis climáticas tradicionais, precipitação e temperatura, e da variável de sensoriamento remoto NDVI. Além disso, busca-se entender o impacto da inclusão do NDVI através de transformadas flexíveis de Fourier, que flexibiliza a relação da variável com a produtividade para a não linearidade, capturando padrões cíclicos da natureza.

Objetivos específicos

NDVI e Soja

Em princípio, com a finalidade de avaliar a premissa de que as variáveis incluídas - principalmente o NDVI - são boas variáveis explicativas para a produtividade de soja, há uma breve apresentação das suas correlações com a produtividade.

Dados de satélite

Para que haja disponibilidade de dados em todos os municípios trabalhados, foi escolhido o uso de dados de satélite, que têm maior abrangência territorial quando comparado à estações metereológicas. Essa escolha também é influenciada pelos padrões do mercado securitário, que costuma preferir esse tipo de dados em seguros paramétricos por serem de acesso público, imparciais e consistentes.

Por isso, antes da aplicação em si dos dados, há um breve comparativo dos dados coletados pelos satélites com os mesmos dados coletados por estações meteorológicas, visando não só atestar sua similaridade, mas também verificar a validade dos dados trabalhados.

Contribuição do índice vegetativo

Será realizado também o comparativo do modelo quadrático com a inclusão do NDVI de forma linear e o modelo com as transformadas flexíveis de Fourier. Nesse comparativo, procura-se inferir a contribuição do NDVI nas duas formas, mostrando que as transformadas trazem maior contribuição, devido a sua flexibilidade e capacidade de captação de padrões cíclicos.

Capacidade preditiva

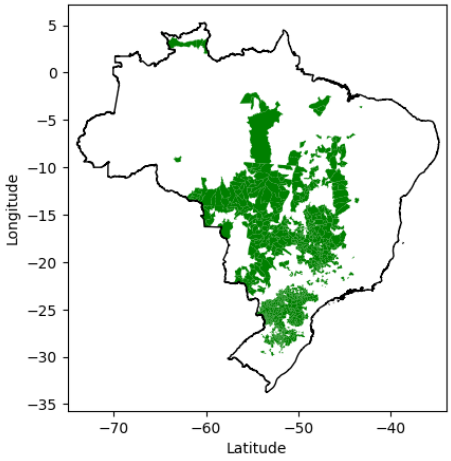
Por fim, com os modelos desenvolvidos e até como técnica de comparação, será avaliada a capacidade de predição e previsão dos modelos. Fica definido, por organização, "predição"como a estimativa de dados com o uso de dados futuros, enquanto "previsão"é a estimativa realizada apenas com dados passados. O objetivo é, além de atestar qual modelo é melhor para a realização das estimativas, também avaliar o erro que eles apresentam nesse processo.

Metodologia

Dados

Municípios

Serão utilizados dados de 1000 municípios de 16 diferentes estados do Brasil ao longo de 19 anos (2006 - 2024). Dessa forma, foram selecionadas os 1000 municípios com maior produtividade média e que tenham dados de produtividade desde 2006, para que não haja valores ausentes no painel de dados. Encontre abaixo a distribuição geográfica da seleção, conforme apresentado na figura 1.



Fonte: Elaboração própria

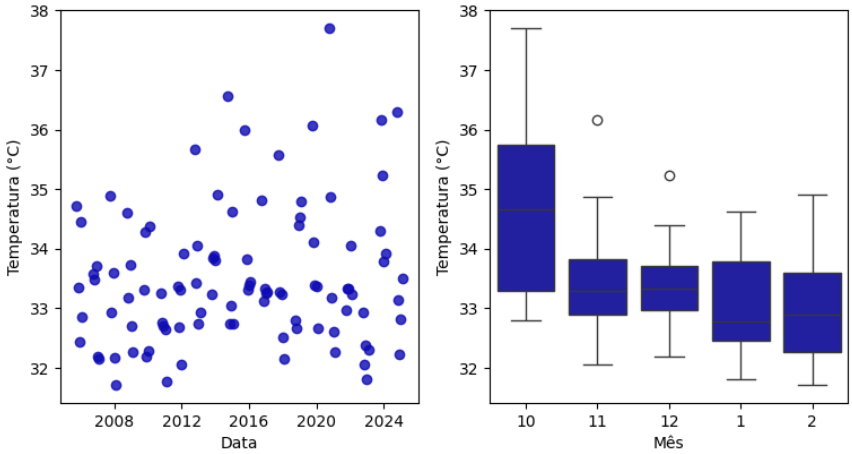
Figura 1: *Municípios selecionados.*

Produtividade

Os dados de produtividade são do sistema IBGE de recuperação automática, na tabela 5457 - Área plantada ou destinada à colheita, área colhida, quantidade produzida, rendimento médio e valor da produção das lavouras temporárias e permanentes, disponibilizado pelo IBGE, 2025a. Nessa base, estão disponíveis diversos tipos de variáveis, produtos, anos e níveis territoriais. Para o estudo, foi selecionado o rendimento médio da produção (Quilogramas por Hectare) para soja (em grão) de 2005 a 2024, a escala municipal.

Temperatura

Para temperatura, serão utilizados os dados de reanálise armazenados na Copernicus Climate Change Service (C3S) (2024), que são a quinta geração de dados de reanálise do Centro Europeu de Previsões Meteorológicas a Médio Prazo (ECMWF), com resolução espacial de 0,25° x 0,25°, disponibilidade desde 1940. Os dados vêm, por padrão, em Kelvin como unidade de medida, mas foram convertidos para graus Celsius pela fórmula $T(^{\circ}C) = T(K) - 273.15$, adotando, assim, a unidade de medida padrão utilizada no Brasil, com o objetivo de facilitar a interpretação dos resultados.



Fonte: Elaboração própria com dados da ERA5

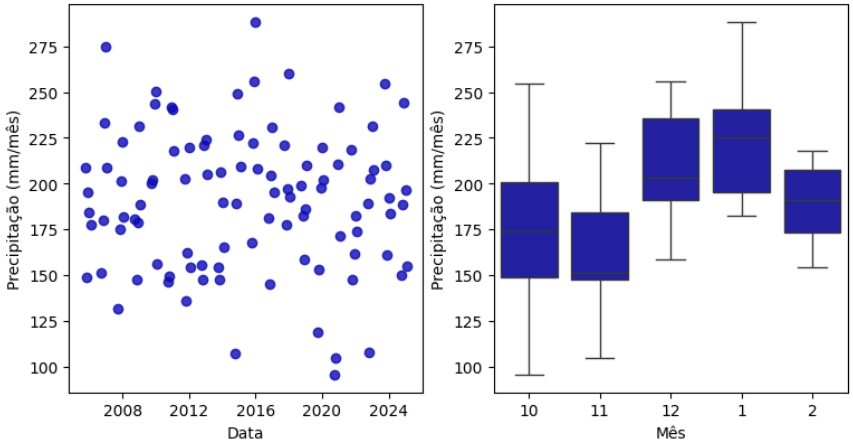
Figura 2: *Gráfico de dispersão e boxplot de temperatura máxima de outubro a fevereiro*

Os gráficos apresentados na figura 2 representam a distribuição da temperatura máxima média dos municípios do estudo de outubro a fevereiro de 2006 à 2025. O gráfico de dispersão exibe uma tendência de crescimento na temperatura máxima ao longo dos anos, enquanto o boxplot ressalta o pico da temperatura máxima média em outubro.

Precipitação

Por outro lado, os dados de precipitação têm como fonte o *Climate Hazards Group Infrared Precipitation with Stations* (CHIRPS), produzido por Funk *et al.* (2014) pelo departamento de geografia da Universidade da Califórnia em Santa Bárbara. Os dados têm uma resolução de 0,05° x 0,05°, com disponibilidade desde 1981. A unidade de medida dos dados vem, por padrão, em mm.

A figura 3 a seguir apresenta a dispersão e a distribuição da precipitação total média para os municípios do estudo. Os gráficos exibem o comportamento cíclico da chuva total, que começa a aumentar em novembro, atingindo seu pico em janeiro para, então, passa a reduzir novamente.



Fonte: Elaboração própria com dados do CHIRPS

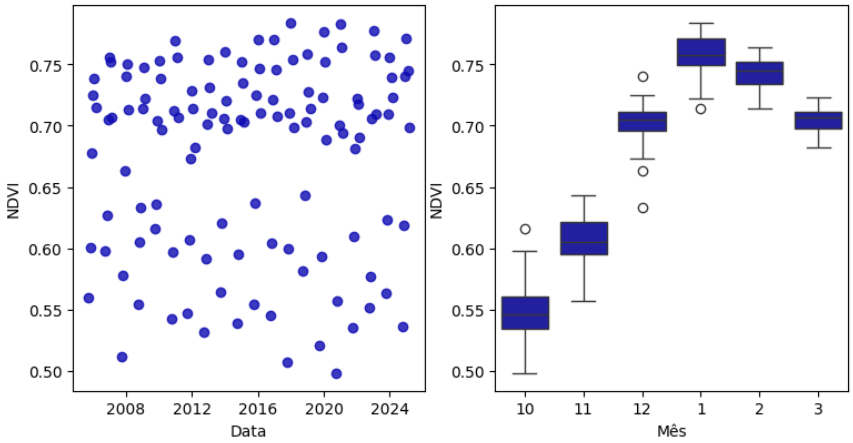
Figura 3: *Gráfico de dispersão e boxplot de precipitação total de outubro a fevereiro*

Estações meteorológicas

Além disso, para efeito de comparação e validação, algumas estações meteorológicas foram selecionadas para realizar o comparativo com os dados de satélite. Essas estações são do Instituto Nacional de Meteorologia (INMET) (s.d.) e estão distribuídas pelo país em diversos municípios e estados, porém com disponibilidades temporais distintas.

NDVI

Por fim, os dados de NDVI foram coletados pelos sensores MODIS, a bordo dos satélites Terra da NASA e disponibilizado por Didan (2021). Os índices de vegetação MODIS, produzidos em intervalos de 16 dias e em múltiplas resoluções espaciais, fornecem comparações espaciais e temporais consistentes da saúde da vegetação. Nesse trabalho, foi selecionado o produto "MOD13C2", com resolução de 0,05° x 0,05°.

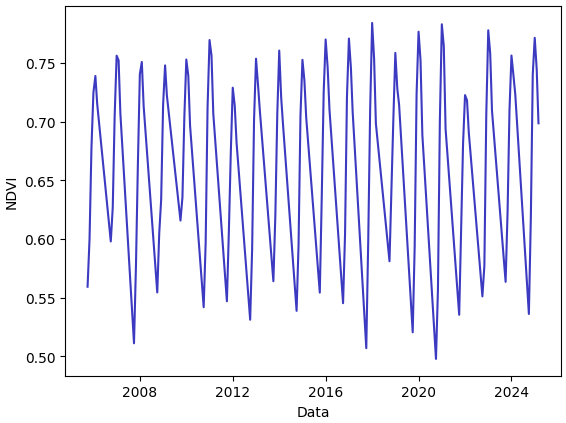


Fonte: Elaboração própria com dados da NASA

Figura 4: *Gráfico de dispersão e boxplot de NDVI médio de outubro a março*

A figura 4 apresenta a dispersão e a distribuição do NDVI para os municípios do estudo. Ainda mais evidente que no gráfico de precipitação, ambos os gráficos exibem o comportamento cíclico do NDVI médio, que começa a aumentar desde outubro, atingindo seu pico em janeiro para, então, passa a reduzir novamente.

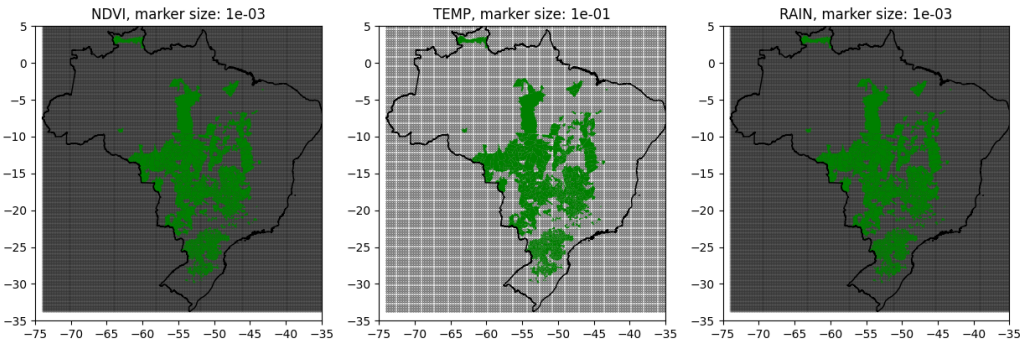
Para evidenciar o comportamento cíclico do NDVI, foi elaborado um gráfico de linha com seus valores, como segue na figura 5. A constante variação dos valores deixa ainda mais evidente esse comportamento do NDVI, o que é essencial para entender o motivo de sua inclusão nas transformações, como será comentado a seguir na seção das transformadas de Fourier.



Fonte: Elaboração própria com dados da NASA

Figura 5: *Gráfico de linhas de NDVI médio de outubro a março*

Para ilustrar a resolução dos dados, na figura 6 exibe-se um demonstrativo dos pontos disponíveis para as três variáveis. O comparativo reforça visualmente a maior precisão espacial das variáveis de NDVI e precipitação, cujas escalas foram reduzidas em 1000 vezes para melhor visualização. A variável de temperatura também apresenta cobertura nacional consistente, com seus valores representados mediante redução de escala em 10 vezes.



Fonte: Elaboração própria

Figura 6: *Resolução das variáveis de satélite.*

Painel de dados

Após a etapa de extração e organização dos dados, faz-se necessário o desenvolvimento de um painel com o resumo daqueles que serão utilizados nos modelos. Seu formato consiste no agrupamento por município, estado e ano de colheita e, para cada uma dessas linhas, obter as variáveis referentes a cada mês de estudo no ciclo de plantação do ano e município em referência, como exemplificado com dados aleatórios na tabela 1.

Município	UF	Ano	Temp. Outubro	Temp. Novembro	Temp. Dezembro	Temp. Janeiro	Temp. Fevereiro
Mangueirinha	PR	2013	32.95	30.80	30.78	30.12	30.78
Ipuã	SP	2017	37.54	33.95	34.82	34.76	34.69
Nova Fátima	PR	2022	30.57	35.09	34.32	34.10	34.10
Pérola d'Oeste	PR	2022	31.73	35.14	37.04	39.24	35.66
São João d'Aliança	GO	2021	40.03	34.30	35.83	34.61	33.69

(a) *Temperatura média*

Município	UF	Ano	Prec. Outubro	Prec. Novembro	Prec. Dezembro	Prec. Janeiro	Prec. Fevereiro
Mangueirinha	PR	2013	266.05	49.19	245.07	179.17	245.93
Ipuã	SP	2017	138.71	209.39	220.05	245.66	151.94
Nova Fátima	PR	2022	188.78	65.30	82.97	82.87	122.46
Pérola d'Oeste	PR	2022	299.52	60.96	17.24	181.19	115.14
São João d'Aliança	GO	2021	133.00	184.15	186.86	98.11	371.52

(b) *Precipitação acumulada*

Município	UF	Ano	NDVI Outubro	NDVI Novembro	NDVI Dezembro	NDVI Janeiro	NDVI Fevereiro	NDVI Março
Mangueirinha	PR	2013	0.59	0.62	0.75	0.83	0.77	0.69
Ipuã	SP	2017	0.40	0.48	0.70	0.77	0.71	0.70
Nova Fátima	PR	2022	0.51	0.55	0.70	0.82	0.85	0.72
Pérola d'Oeste	PR	2022	0.55	0.60	0.68	0.59	0.60	0.67
São João d'Aliança	GO	2021	0.41	0.55	0.66	0.72	0.67	0.64

(c) *NDVI médio*

Município	UF	Ano	Produtividade Soja
Mangueirinha	PR	2013	3362
Ipuã	SP	2017	3626
Nova Fátima	PR	2022	3540
Pérola d'Oeste	PR	2022	722
São João d'Aliança	GO	2021	2976

(d) *Produtividade da soja*

Fonte: Elaboração própria

Tabela 1: *Linhas aleatórias do painel de dados utilizado nos modelos*

Regressão quadrática

A estimação de parâmetros através de uma regressão linear estimada pelo método dos mínimos quadrados ordinários (OLS) é amplamente utilizada tanto para modelos causais, como no artigo de Angrist e Krueger (1991), que utiliza regressões para quantificar o efeito da época do nascimento em uma variedade de variáveis de resultados educacionais, mas também para modelos preditivos, como no artigo de Wang *et al.* (2023) em que a regressão é utilizada para prever preços de ações.

Entretanto, esse modelo parte da premissa de que a variável explicada segue uma relação aproximadamente linear com as variáveis explicativas. Uma forma de contornar essa premissa é incluir os regressores também em sua forma quadrática. Assim, os parâmetros continuarão sendo estimados de forma linear, mas os regressores têm amplitude quadrática. Dessa forma, supondo um β_1 estimado para a variável em sua forma linear e β_2 estimado para a forma quadrática, enquanto β_1 indica o efeito marginal inicial, β_2 indicará como o efeito marginal muda conforme x.

Tranformadas de Fourier

A síntese da teoria de Fourier é aproximar qualquer função periódica, como o NDVI, através de uma soma finita - para dados discretos - de senos e cossenos. Dessa forma, transformações de Fourier expressam séries $f(t)$ como uma soma de funções senoidais com diferentes frequências e fases, como exibido na equação 2, em que a_i e b_i representam os coeficientes de amplitude, i a frequência angular e n (quantidade de i) a ordem da transformada.

$$f(t) = a_0 + \sum_{i=1}^{n} a_i cos(it) + b_i sin(it) \tag{2}$$

O papel da regressão em nosso modelo será justamente estimar os coeficientes de amplitude para avaliar como a oscilação do NDVI afeta a produtividade.

O modelo

Dessa forma, a equação que descreve o modelo FFT está descrita a seguir pela equação 3.

$$\begin{aligned} Soja\,(kg/ha) = \beta_0 \; &+ \sum_{m=Outubro}^{Fevereiro} (\beta_{1m} TempMax_m + \beta_{2m} TempMaxQuad_m) \\ &+ \sum_{m=Outubro}^{Fevereiro} (\beta_{3m} Prec_m + \beta_{4m} PrecQuad_m) \\ &+ \sum_{m=Outubro}^{Marco} (\beta_{5m} NDVI_m) + \delta_0 TendAnual + \sum_{s=1}^{15} \delta_s DummyEstado_s \\ &+ 2 \sum_{\alpha=1}^{A} \sum_{j=1}^{J} \{v_{j\alpha} cos[j k_\alpha^T s(NDVI)] - w_{j\alpha} sin[j k_\alpha^T s(NDVI)]\} \end{aligned} \tag{3}$$

Nesse modelo, a variável dependente é a produtividade de soja em um estado em um dado ano. β_0 é o intercepto e $TempMax_m$, $Prec_m$ e $NDVI_m$ correspondem, respectivamente, à temperatura máxima, precipitação total e NDVI médio no mês m. Para temperatura e precipitação foram incluídos também seus valores na forma quadrática, representados por

$TempMaxQuad_m$ e $PrecQuad_m$, respectivamente. Os meses escolhidos para cada variável seguem a referência de Xu e Katchova (2019), adaptados ao contexto brasileiro.

$TendAnual$ se refere à diferença do ano com 2005, variando, assim, de 1 a 19. As variáveis $DummyEstado_s$, por sua vez, referem-se às variáveis dummys de estado para os 16 estados do estudo. Essas variáveis formam o modelo que precede a inclusão das transformadas de Fourier e que será chamado de "Modelo OLS"no restante do trabalho.

Para incluir as transformadas e descrever o "Modelo FFT", inclui-se a segunda parte $2\sum_{\alpha=1}^{A}\sum_{j=1}^{J}\{v_{j\alpha}cos[jk'_\alpha s(NDVI)] - w_{j\alpha}sin[jk'_\alpha s(NDVI)]\}$ em que $NDVI$ é um vetor cujos elementos são $NDVI_m$ e $s(NDVI)$ é a forma padronizada desse vetor, variando de 0 a 2π.

Quanto aos coeficientes, $\beta_{1m}, \beta_{2m}, \beta_{3m}, \beta_{4m}$ e β_{5m} são os multiplicadores da temperatura máxima, temperatura máxima ao quadrado, precipitação total, precipitação total ao quadrado e NDVI médio para o mês m, respectivamente. δ_0 é o coeficiente da tendência anual, enquanto $\delta_s, s \in [1, 15]$ parametriza as dummys de estado.

k_α são vetores multi-índice elementares com dimensão igual à de $NDVI$ e A representa a quantidade total desses vetores. Esse vetor pode ser obtido a partir de dois filtros aplicados a todos k_α que tenham apenas elementos inteiros e cuja soma dos valores absolutos dos elementos seja menor ou igual a K. O primeiro elemento diferente de zero deve ser positivo e os elementos devem ser primos entre si. Além disso, para mitigar o risco de *overfitting*[1], foram consideradas apenas relações positivas associadas ao NDVI, impondo-se a restrição de que todos os elementos sejam maiores ou iguais a zero.

O produto desse vetor transposto corresponde a uma combinação linear, isto é, $k_\alpha^T s(NDVI)$ não passa de uma combinação linear dos vetores de $s(NDVI)$. Além disso, J representa a ordem da transformação de Fourier e $v_{j\alpha}$ e $w_{j\alpha}$ são os parâmetros a serem estimados.

No modelo foram definidos $K = 2$ e $J = 2$, o que, analiticamente, implica que as transformadas captam a interação de até dois meses entre si ($K = 2$) e de até dois ciclos ($J = 2$). Os valores de K e J foram escolhidos seguindo a referência do artigo Xu e Katchova (2019), que segue a regra geral de que o número de variáveis depois da transformação seja aproximadamente a raiz quadrada do número de observações relatada por Fenton e Gallant (1996). Mas note que $J = 2$ também tem sentido econômico, visando a captura de um período mais seco e um período mais úmido.

Por fim, o modelo OLS consiste no modelo FFT para $v_{j\alpha} = w_{j\alpha} = 0$ e, assim, o teste de hipótese de rejeição do modelo OLS em favor do FFT pode ser realizado pela significância estatística desses coeficientes.

Poder preditivo

Apresentados os distintos modelos que serão estimados no desenvolvimento do trabalho, é preciso mensurar como será feita a avaliação de desempenho de cada um deles, permitindo, assim, uma comparação. Para isso, foram realizadas estimativas fora de amostra,

[1] Quando um modelo se ajusta muito bem a um conjunto de dados, mas não pode ser generalizado.

com duas diferentes formas de cálculo de erro para avaliação de performance: a raiz do erro quadrático médio (RMSE) e o erro absoluto médio (MAE), conforme descrito na equação 4.

$$\begin{aligned} RMSE &= \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} \\ MAE &= \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i| \end{aligned} \tag{4}$$

Com y_i sendo o valor real da produtividade e $\hat{y}_i$ o valor estimado pela regressão, a unidade final dos erros é a mesma da produtividade inicial: kg/ha.

O comparativo será realizado em três formas: previsão em séries temporais, previsão seccional e previsão em painel. Isto é, será avaliado o erro da previsão para o ano, para o estado e para o ano em um estado. Desse modo, para a previsão em séries temporais, deve-se fixar o ano a ser avaliado, que terá o valor de sua produtividade predita pelos modelos treinados com os dados dos outros anos. A previsão seccional é similar, mas a seleção é feita a nível estadual, em que se fixa um estado para ser removido da amostra e previsto pelo modelo. Por fim, a previsão em painel une ambos os conceitos, fixando um estado e um ano para a avaliação.

Resultados

As variáveis

Correlações

Analisar a correlação das variáveis explicativas é um método comum para avaliar o potencial delas para um modelo explicativo, como explica Miot (2018) em seu artigo sobre análise de correlação em estudos clínicos e experimentais, no qual o autor chega a classificar a força das correlações entre 0; 0,3; 0,5; 0,7 e 0,9.

Mesmo que a correlação não implique em causalidade, ainda assim ela apresenta um bom indício de tendência, visto que mede como as variáveis se movem juntas, indica se quando o valor de uma sobe o valor da outra acompanha ou tende a descer. Assim a tabela 2 exibe algumas descritivas das correlações agrupadas estado a estado.

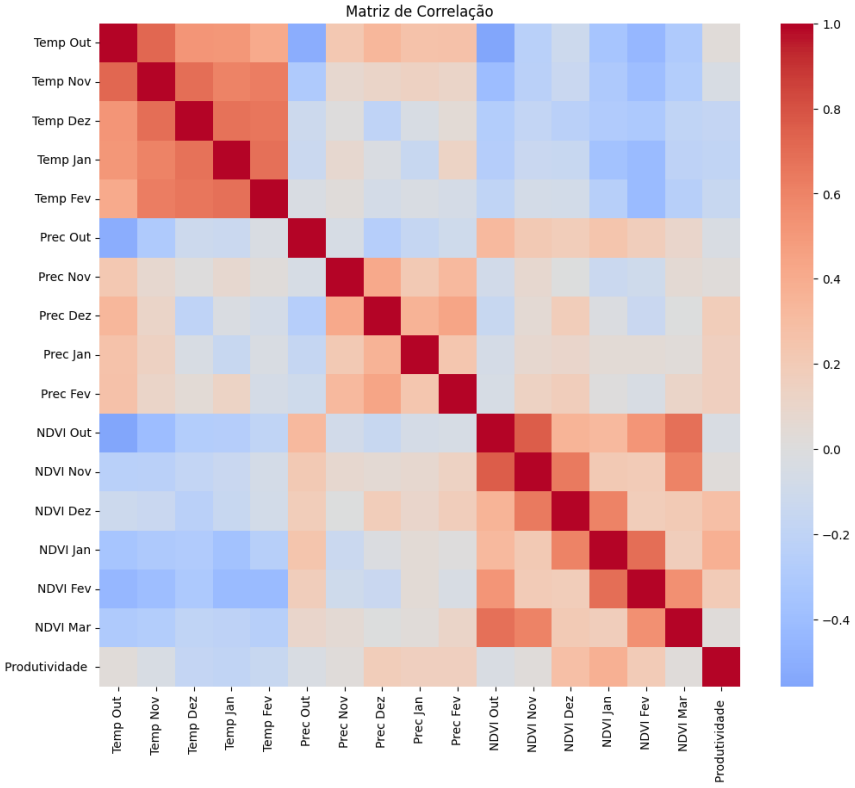
	Média	Mínimo	Mediana	Máximo
NDVI Jan	0.35	-0.02	0.38	0.75
NDVI Fev	0.22	-0.22	0.25	0.65
NDVI Dez	0.22	-0.07	0.26	0.45
Prec Fev	0.19	-0.15	0.19	0.47
Temp Dez	-0.14	-0.37	-0.12	0.13
Temp Jan	-0.13	-0.35	-0.14	0.18
Temp Fev	-0.1	-0.42	-0.12	0.16
Prec Dez	0.1	-0.16	0.05	0.44
Temp Nov	-0.06	-0.3	-0.06	0.21
NDVI Out	-0.06	-0.35	-0.07	0.06
NDVI Mar	0.05	-0.18	0.05	0.3
Temp Out	0.04	-0.17	0.02	0.21
NDVI Nov	0.02	-0.22	0.05	0.19
Prec Jan	0.02	-0.38	0.02	0.56
Prec Nov	0.02	-0.18	-0.01	0.31
Prec Out	-0.0	-0.25	0.02	0.24

Fonte: Elaboração própria

Tabela 2: *Correlações entre as principais variáveis e produtividade a nível estadual*

A tabela ressalta o destaque do NDVI, que forma o top 3 das variáveis com maior correlação média para os meses de janeiro, fevereiro e dezembro, justamente os meses típicos de florescimento, enchimento e maturação dos grãos. Esses mesmos meses aparecem como os de maiores correlações absolutas, todas negativas, com temperatura, indicando o perigo de secas nesse período crítico da plantação.

Além de analisar a correlação das variáveis explicativas com a dependente, também é de suma importância analisar a correlação das variáveis exógenas entre si, pois inserir variáveis muito semelhantes pode causar multicolinearidade, dificultando a interpretação precisa dos efeitos de cada variável.



Fonte: Elaboração própria

Figura 7: *Heatmap da matriz de correlação das principais variáveis*

Como exibido na figura 7, as maiores correlações são de variáveis climáticas com as mesmas em períodos vizinhos, como temperatura de outubro com temperatura de novembro ou NDVI de outubro com NDVI de novembro. Entretanto, no geral essa correlação não é tão alta, de forma em que as únicas correlações maiores ou iguais a 0.7, classificadas como fortes por Miot (2018), são justamente as duas relações citadas de temperatura e NDVI.

Satélites e Estações metereológicas

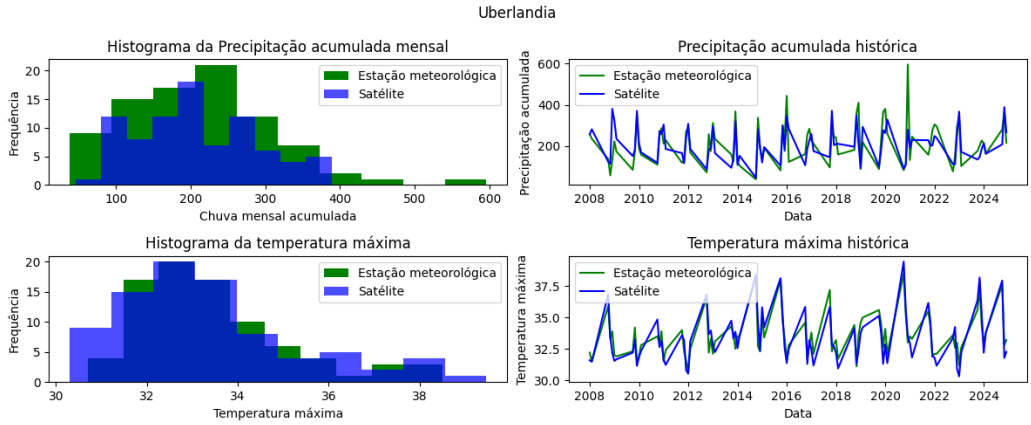
Para o processo de validação dos dados utilizados, foram selecionadas 7 cidades do estudo que têm estação meteorológica do INMET.

Município	Estado
Alto Taquari	MT
Castro	PR
Chapeco	SC
Pires Do Rio	GO
Uberaba	MG
Uberlandia	MG
Xanxere	SC

Tabela 3: *Cidades para comparativo entre satélite e estações meteorológicas.*

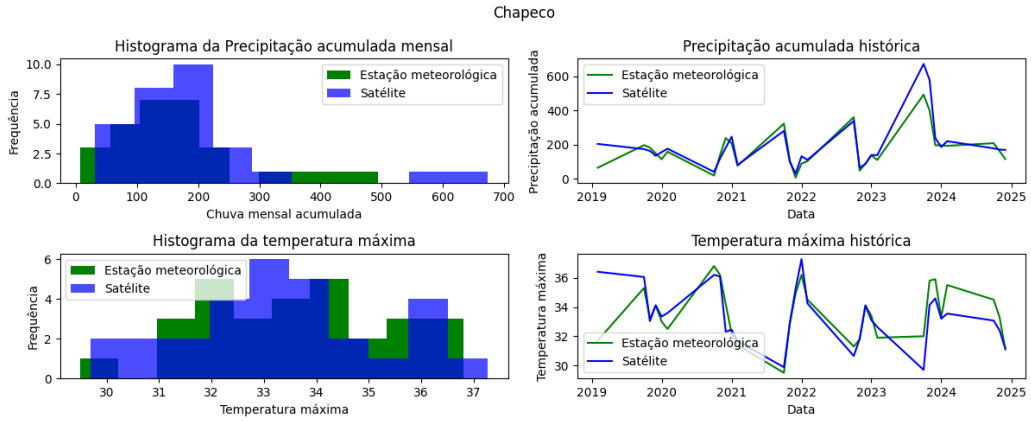
Visual

Com a finalidade de fazer uma comparação visual dos dados registrados pelos dois tipos de coleta de dados, as figuras 8 e 9 apresentam histogramas e gráficos de linhas para o histórico dos dados de precipitação e para o histórico dos dados de temperatura.



Fonte: Elaboração própria com dados do CHIRPS, ERA5 e INMET

Figura 8: *Visuais de comparação de satélite e estação metereológica para Uberlândia*



Fonte: Elaboração própria com dados do CHIRPS, ERA5 e INMET

Figura 9: *Visuais de comparação de satélite e estação metereológica para Chapecó*

Os gráficos exibem que o comportamento dos dados é parecido, apesar de diferirem em alguns pontos. Em Uberlândia há um indício de menor captura de *outliers* pelos satélites, devido ao pico em 2023, o que não apresenta uma grande problemática para um modelo baseado em OLS, que justamente regride a média.

Diferença absoluta

Outra forma de analisar a semelhança entre os métodos de coleta é analisar suas diferenças absolutas. A lógica do cálculo é a mesma do RMSE e MAE definidos na equação 4, entretanto sem ter realmente um valor correto para referência, não sendo, assim, definido um erro.

Chamando de raiz da diferença média ao quadrado (*RMSD - root mean squared difference*) e diferença média absoluta (*MAD - mean absolut difference*), obteve-se o reportado na tabela 4, em que a unidade de medida para precipitação é mm acumulado no mês e temperatura °C.

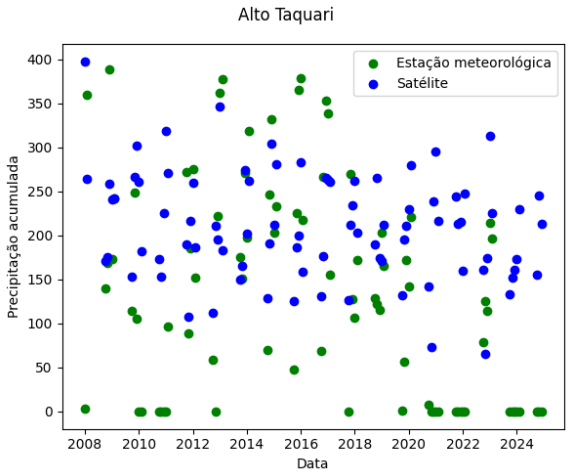
	MAD		RMSD	
Município	Precip	Temp	Precip	Temp
Pires Do Rio	53.54	1.5	71.55	1.69
Uberlandia	48.24	0.68	69.74	0.83
Uberaba	75.36	0.63	98.83	0.74
Castro	66.55	0.76	90.89	0.9
Xanxere	60.78	1.06	88.81	1.38
Chapeco	38.82	0.82	60.26	1.27
Alto Taquari	109.68	0.66	138.37	0.89

Fonte: Elaboração própria

Tabela 4: *Diferenças entre as diferentes fontes de dados de temperatura e precipitação*

O resultado indica que temperatura tem maior similaridade entre as diferentes fontes de dados. Para efeito de comparação a média da temperatura máxima e da precipitação total de todo o conjunto de dados é 33,52°C e 191,12mm/mês. Assim, para temperatura o erro em relação a média satelital varia de 1,8% à 5,04%, enquanto a precipitação vai de 20,31% à 72.4%.

Vale ressaltar que as estações nem sempre terão dados, pois estão sujeitas a erros, como sensores danificados, acúmulo de sujeira, fiação, entre outros, o que fortifica a ideia da utilização de dados de satélite, principalmente os da ERA5 (temperatura) ou CHIRPS (precipitação), que passam por um processo de validação. A figura 10, por exemplo, exibe um caso em que a estação indica que em 25 meses não houve chuva na cidade.



Fonte: Elaboração própria com dados do CHIRPS e INMET

Figura 10: *Dispersão da precipitação total em Alto Taquari para satélite e estação meterológica*

Análise descritiva

As estatísticas descritivas das principais variáveis do estudo estão descritas na tabela 5. A produtividade média de 2006 a 2024 de todos os estados foi de 2080,35 kg/ha. Os dados exibem o que foi apresentado anteriormente pelas figuras 2, 3 e 4, em que a temperatura máxima média mostra uma tendência de diminuição de outubro a fevereiro, enquanto a precipitação total média e o NDVI médio exibem uma tendência de crescimento. Os picos positivos ocorrem em outubro, janeiro e janeiro para temperatura, precipitação e NDVI, respectivamente.

	Número de observações	Mínimo	Mediana	Máximo	Média	Desvio padrão
Produtividade de soja	19000	271.0	3100.0	7670.0	3080.35	580.07
Temperatura máxima outubro	19000	24.74	34.87	43.58	34.55	3.37
Temperatura máxima novembro	19000	25.42	33.48	42.1	33.48	2.45
Temperatura máxima dezembro	19000	27.07	33.38	41.16	33.39	1.93
Temperatura máxima janeiro	19000	27.27	33.1	40.04	33.1	1.93
Temperatura máxima fevereiro	19000	26.74	33.06	39.52	33.04	1.92
Precipitação total outubro	19000	4.56	152.37	846.4	172.85	95.59
Precipitação total novembro	19000	4.29	147.91	737.75	161.76	80.27
Precipitação total dezembro	19000	7.99	200.0	577.86	204.34	90.52
Precipitação total janeiro	19000	3.37	215.96	656.92	226.18	84.62
Precipitação total fevereiro	19000	5.67	179.09	640.49	189.98	79.07
NDVI outubro	19000	0.26	0.55	0.85	0.55	0.12
NDVI novembro	19000	0.28	0.61	0.87	0.61	0.1
NDVI dezembro	19000	0.31	0.7	0.91	0.7	0.08
NDVI janeiro	19000	0.3	0.76	0.93	0.76	0.07
NDVI fevereiro	19000	0.29	0.74	0.91	0.74	0.07
NDVI março	19000	0.27	0.71	0.88	0.7	0.07

Fonte: Elaboração própria

Tabela 5: *Estatísticas descritivas do painel de dados*

Modelo FFT

Resumo

Uma das principais métricas para descrever a qualidade do ajuste de um modelo como um todo é o coeficiente de determinação R^2. Essa métrica mede a proporção da variabilidade na variável endógena que é explicada pelas variáveis independentes do modelo e varia de 0 a 1, em que 0 indica nenhum ajuste dos dados e 1 um ajuste perfeito. Vale ressaltar que um R^2 alto não indica causalidade, apenas sugere uma forte relação.

Quando analisados os coeficientes individualmente, uma métrica relevante é o *p-valor*, que indica o nível de significância do coeficiente. Um *p-valor* de 0,05 indica um coeficiente com nível de significância de 5%.

	Coef FFT	Coef OLS
Temp Out	-29.3583	-50.4122**
Temp Nov	-8.0441	-22.9086
Temp Dez	407.0221***	369.3418***
Temp Jan	162.0766***	124.3116**
Temp Fev	28.5923	2.1561
Prec Out	-0.7331***	-0.6913***
Prec Nov	-0.9647***	-0.7645***
Prec Dez	4.5568***	4.9728***
Prec Jan	3.0758***	3.2817***
Prec Fev	2.0381***	2.0970***
NDVI Out	204.0259*	-140.1551*
NDVI Nov	-232.8344	-11.4742
NDVI Dez	602.4651***	317.6600***
NDVI Jan	2360.2162***	2177.7268***
NDVI Fev	-592.1601***	320.5278***
NDVI Mar	-38.8063	-92.2391
Número de observações	19000	19000
Efeito fixo de Estado	Sim	Sim
Efeito de tendência anual	Sim	Sim
R^2 ajustado	0.465	0.443

Fonte: Elaboração própria

Tabela 6: *Resultados gerais dos modelos*

A tabela 6 exibe os coeficientes dos modelos de Fourier e OLS simples, com os asteríscos *, ** e *** indicando, respectivamente, os níveis de signficância de 10%, 5% e 1%.

Pode-se notar um ajuste levemente maior do R^2 para o modelo FFT. Quanto aos coeficientes, pode-se perceber maior similaridade para as variáveis de temperatura máxima e precipitação, o que não é válido para as variáveis de NDVI. Isso ocorre, pois a inclusão das transformadas com senos e cossenos de diversas frequências torna o modelo altamente não linear para o NDVI e assim cada coeficiente contribui apenas parcialmente para a

forma global da relação estimada entre essas variáveis e a produtividade.

Elasticidade

Para contornar isso e comparar os modelos de forma mais eficiente, pode-se utilizar a estimativa de elasticidade para cada variável. O cálculo da elasticidade é resultado do produto da derivada da variável explicada em relação à variável explicativa com a razão da variável explicativa com a variável explicada, conforme demonstrado na equação 5.

$$El(x) = \frac{\partial Y}{\partial x}\frac{x}{Y(x)} \tag{5}$$

Em modelos com coeficientes lineares, como consequência do teorema do valor médio, descrito no teorema 1, a derivada é simplesmente o coeficiente.

Teorema 1. *Seja f uma função contínua em $[a, b]$ e diferenciável em (a, b). Então existe um ponto c em (a, b) tal que:*

$$f'(c) = \frac{f(b) - f(a)}{b - a}$$

Com o intuito de calcular a elasticidade de forma seccional, foram fixadas o valor das variáveis independentes em suas medianas para cada estado, com um cálculo final conforme a equação 6, obtendo os resultados descritos na tabela 7

$$E_{var,UF} = \beta_{var} \cdot \frac{X_{med_UF}}{\hat{Y}_{UF}} \tag{6}$$

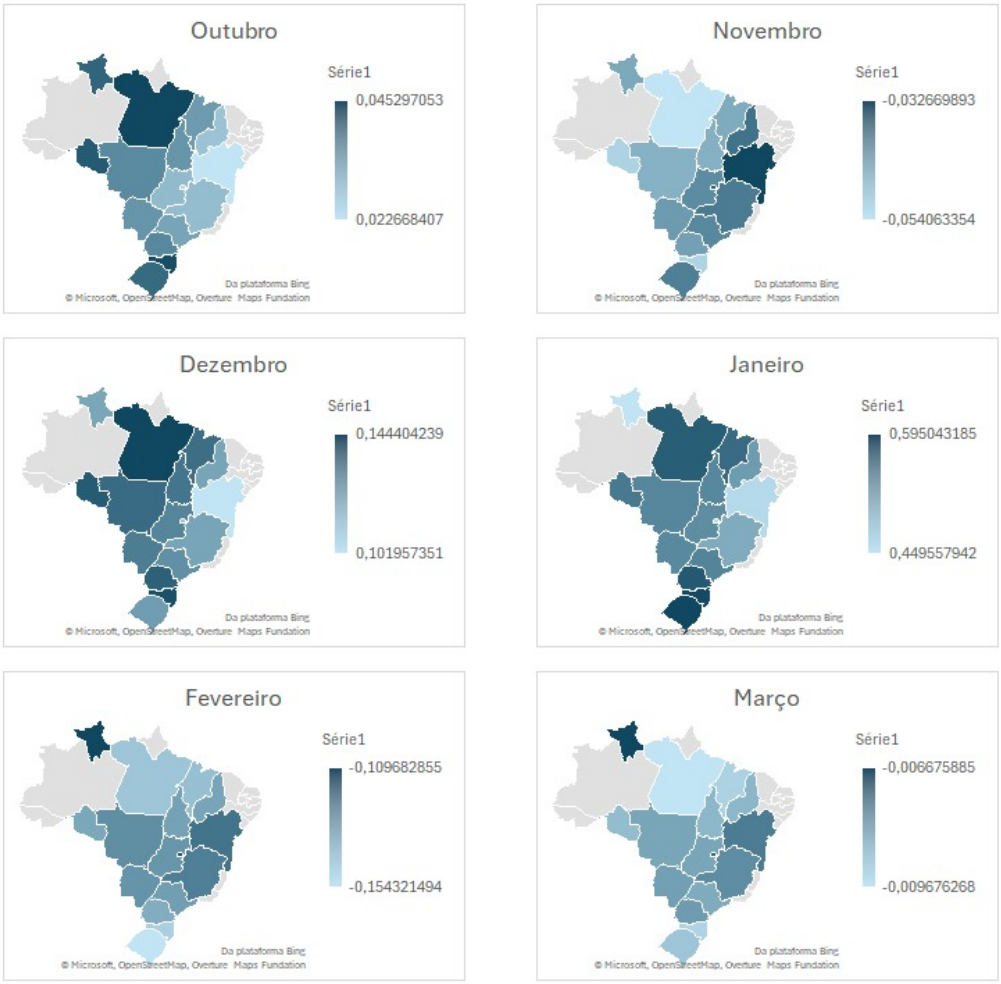
	FFT			OLS		
	Mínima	Mediana	Máxima	Mínima	Mediana	Máxima
Temp Out	-0.38	-0.33	-0.28	-0.71	-0.57**	-0.49
Temp Nov	-0.1	-0.09	-0.08	-0.32	-0.24	-0.22
Temp Dez	3.93	4.22***	5.1	3.57	3.90***	5.01
Temp Jan	1.57	1.67***	2.04	1.2	1.30**	1.7
Temp Fev	0.27	0.29	0.36	0.02	0.02	0.03
Prec Out	-0.05	-0.03***	-0.01	-0.05	-0.02***	-0.01
Prec Nov	-0.07	-0.05***	-0.03	-0.06	-0.04***	-0.02
Prec Dez	0.09	0.28***	0.38	0.11	0.31***	0.41
Prec Jan	0.03	0.21***	0.28	0.04	0.22***	0.3
Prec Fev	0.03	0.12***	0.19	0.03	0.12***	0.2
NDVI Out	0.02	0.03*	0.05	-0.03	-0.02*	-0.02
NDVI Nov	-0.05	-0.04	-0.03	-0.0	-0.00	-0.0
NDVI Dez	0.1	0.13***	0.14	0.05	0.07***	0.08
NDVI Jan	0.45	0.54***	0.6	0.42	0.50***	0.57
NDVI Fev	-0.15	-0.13***	-0.11	0.06	0.07***	0.09
NDVI Mar	-0.01	-0.01	-0.01	-0.02	-0.02	-0.02

Fonte: Elaboração própria

Tabela 7: *Elasticidades dos modelos*

Apenas as variáveis principais foram incluídas por facilidade de visualização, mas no cálculo do $\hat{Y}_{UF}$ todas foram consideradas, adicionando as transformadas para o modelo FFT. Os resultados das elasticidades sugerem, em ambos os modelos, que o NDVI médio de janeiro, a precipitação total de dezembro e a temperatura máxima de dezembro têm grande associação à produtividade final. De acordo com a tabela 7, um aumento de 10% no NDVI em janeiro corresponde a um aumento de 5,4% de produtividade, o que corresponde a 166,34kg/ha, tomando o valor médio exibido na tabela 5.

A distribuição geográfica por estado das elasticidades do modelo FFT está exibida na figura 11. Em outubro, nota-se uma forte concentração da sensibilidade nas regiões norte e sul, com o máximo chegando a 0,045 no Pará. Em dezembro e janeiro, meses com maiores elasticidades, a relevância fica bem distribuída, com maior relevância no norte do país, mas com grande destaque para as regiões Sul e Centro-Oeste.



Fonte: Elaboração própria com dados da NASA

Figura 11: *Distribuição geográfica da elasticidade estimada do modelo FFT para NDVI*

Teste de hipótese

A elasticidade apresenta um bom indício de que o modelo FFT tem vantagens quando comparado ao modelo OLS, mas isso pode ser reflexo de *overfitting* devido à adição de novas 84 variáveis. Para isso pode-se testar a hipótese nula descrita na equação 7

$$H_0 : v_{j\alpha} = w_{j\alpha} = 0, \alpha \in [1, 21], j \in [1, 2] \tag{7}$$

que resultou em um p estatisticamente igual a 0 ($2.94 \cdot 10^{-220}$), rejeitando a hipótese nula e reforçando que os termos Fourier são conjuntamente significativos e o modelo FFT melhora estatisticamente o ajuste em relação ao modelo OLS.

Além disso, para avaliar a potencial melhora com a a inclusão dos termos pode-se utilizar a Análise de Variância (ANOVA), conforme destaca Gelman e Hill (2006). Esse método testa, por meio do teste F, se a redução na soma dos quadrados residuais ao passar de um modelo mais simples para um mais complexo é estatisticamente significativa.

Aplicando o ANOVA no modelo OLS contra o FFT obteve-se o resultado da tabela 8.

df_resid	ssr	df_diff	ss_diff	F	Pr(>F)
18957	$3,56 \cdot 10^9$	0			
18873	$3,4 \cdot 10^9$	84	$160,52 \cdot 10^6$	10.61	0

Fonte: Elaboração própria

Tabela 8: *ANOVA aplicado nos modelos*

Reforçando a significância das inclusões no modelo, uma vez que o $p - valor$ é estatisticamente igual a 0, com uma redução de 160, 52 milhões de unidades no erro calculado pela soma dos quadrados do resíduo. Isso equivale a uma média de 91,91 kg/ha, com a média de produtividade descrita na tabela 5 e o cálculo do RMSE descrito na equação 4. Economicamente, esse valor corresponde à R$ 217,37 por hectare, utilizando o valor da saca de Soja de 27 de novembro de 2025, disponibilizado pela CEPEA – Centro de Estudos Avançados em Economia Aplicada (2025).

Predição fora da amostra

A tabela 9 contém os resultados para a predição em séries temporais (9a) e a predição seccional (9b), em que o modelo FFT superou o modelo OLS em 10 anos (52,63%) pelo MAE, em 11 anos (57,84%) no RMSE e em 11 estados (68,75%) em ambas as métricas de erro. Valores em negrito indicam linhas em que o modelo FFT foi superior ao OLS, isto é, teve um erro menor.

	MAE		RMSE	
Ano	OLS	FFT	OLS	FFT
2006	**323.72**	**318.69**	**409.54**	**406.33**
2007	282.91	285.77	389.07	390.39
2008	249.12	257.97	321.72	332.49
2009	317.0	320.53	445.0	446.27
2010	281.01	303.12	360.55	388.5
2011	**267.39**	**265.84**	**377.18**	**376.42**
2012	323.29	328.4	425.65	435.01
2013	**292.2**	**290.85**	**392.37**	**391.27**
2014	**356.86**	**350.73**	**481.68**	**470.83**
2015	**312.39**	**308.72**	**414.15**	**410.33**
2016	**373.79**	**365.17**	**495.38**	**486.15**
2017	**359.24**	**354.31**	**449.21**	**445.08**
2018	322.05	322.3	**423.67**	**418.22**
2019	**371.57**	**356.58**	**485.63**	**466.37**
2020	377.33	382.51	498.36	506.19
2021	315.14	322.0	415.89	419.25
2022	**557.47**	**525.58**	**750.58**	**720.04**
2023	**339.81**	**322.69**	**445.85**	**422.61**
2024	410.74	424.61	525.27	538.54

(a) *Análise temporal*

	MAE		RMSE	
UF	OLS	FFT	OLS	FFT
MG	**301.54**	**294.77**	**405.15**	**397.87**
GO	**253.29**	**251.48**	**342.43**	**337.91**
PR	**328.2**	**323.14**	**441.7**	**434.35**
SC	**362.31**	**351.74**	**460.27**	**448.25**
SP	**420.92**	**417.16**	**556.37**	**549.76**
MS	316.01	321.28	425.68	427.17
TO	**242.82**	**240.17**	**311.14**	**306.34**
RS	**371.53**	**348.48**	**476.47**	**446.13**
PA	361.85	364.14	471.64	474.51
RR	**667.21**	**562.39**	**805.71**	**689.93**
MT	**223.32**	**218.54**	**292.5**	**284.8**
MA	**264.98**	**262.53**	**363.45**	**361.37**
PI	389.05	392.3	**535.79**	**534.68**
BA	388.37	390.2	508.8	509.34
DF	180.15	185.11	219.3	232.63
RO	**235.1**	**231.08**	308.7	311.55

(b) *Análise seccional*

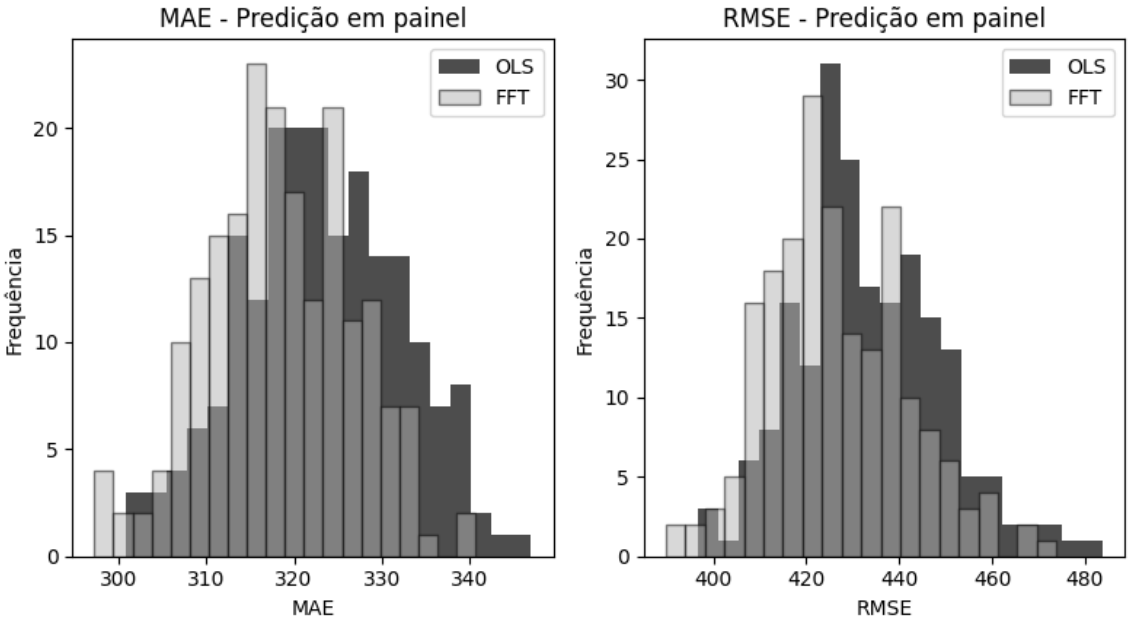
Fonte: Elaboração própria

Tabela 9: *Desempenho na predição fora de amostra*

O maior dos erros das predições em séries temporais foi em 2020, o que é justificado pela quebra de safra que ocorreu no mesmo ano, com um resultado médio 14,71% abaixo do ano anterior nos municípios de estudo, quebrando a tendência de crescimento da série. Além disso, o maior dos erros das predições seccionais foi em Roraima, que tem a menor média de produtividade dos estados selecionados, além de ser geograficamente o mais afastado dos demais, como ilustrado na figura 1, o que pode causar grandes diferenças nas condições climáticas e seu comportamento com a cultura plantada.

Também foi realizado um processo de predição em painel através do método de Monte Carlo. 1000 observações de todos os anos e estados do painel de dados foram aleatoriamente selecionadas e preditas pelos modelos OLS e FFT ajustados com as outras 18000 observações. Assim, para calcular os erros, foram comparados os valores preditos por esses modelos para essas 1000 observações e os dados reais, através do MAE e RMSE. Esse processo foi repetido por 200 vezes para melhor ajuste estatístico.

Os histogramas da figura 12 comparam os resultados nas duas métricas de erro. O deslocamento mais à esquerda dos dados do modelo FFT em ambos os gráficos evidencia sua maior eficácia na predição em painel. A média em si dos modelos é relativamente próxima, mas o FFT é ressaltado por concentrar menos valores na cauda direita da distribuição, indicando maior controle para grandes erros.



Fonte: Elaboração própria

Figura 12: *Desempenho na predição em painel*

A tabela 10 exibe os erros médios para cada uma das predições realizadas e nos três métodos o modelo FFT superou o OLS em ambos os erros, melhorando a performance em 0,15% até 1,94%, como indicado nas colunas "GANHO". O cálculo do ganho de performance é obtido através da divisão entre a diferença dos erros dos modelos e a produtividade média de 2080,35kg/ha, previamente exibida na tabela 5.

Além disso, algo interessante de analisar na tabela 10 é a diferença dos erros na predição seccional e em painel com os erros da predição em séries temporais. Isso indica que, ao realizar uma predição, caso haja dados disponíveis de outras regiões, é extremamente vantajoso inseri-los no ajuste do modelo. Por outro lado, as colunas de ganho de performance mostram como a flexibilidade das transformadas faz ainda mais efeito na predição temporal, devido sua maior instabilidade.

	MAE		RMSE		GANHO	
	OLS	FFT	OLS	FFT	MAE	RMSE
Temporal	458.47	398.71	569.66	512.83	1.94%	1.84%
Seccional	331.67	322.16	432.82	421.66	0.31%	0.36%
Painel	323.03	318.28	433.28	426.41	0.15%	0.22%

Fonte: Elaboração própria

Tabela 10: *Comparativo dos três métodos de predição*

Previsões e o desempenho em 2025

Todas as predições realizadas até agora usavam também dados futuros como base para o cálculo. Entretanto, em uma aplicação real, previsões utilizam dados passados para estimar algo no futuro.

Previsões históricas - *Backtest*

	MAE		RMSE	
Ano	OLS	FFT	OLS	FFT
2007	**2209.59**	**1173.85**	**2259.38**	**1282.1**
2008	**315.13**	**306.79**	**405.45**	**398.62**
2009	**375.7**	**374.85**	**525.01**	**522.17**
2010	292.82	303.89	368.89	386.86
2011	**317.19**	**313.31**	**417.52**	**413.17**
2012	373.91	375.66	495.01	495.09
2013	279.87	280.65	376.41	380.74
2014	343.73	347.19	469.01	470.39
2015	294.78	297.94	399.47	400.49
2016	366.48	370.25	492.71	497.26
2017	**406.55**	**396.12**	**492.83**	**483.18**
2018	307.86	308.37	**404.27**	**403.76**
2019	**357.35**	**346.58**	**469.91**	**457.33**
2020	**388.21**	**386.79**	**521.53**	**519.34**
2021	304.05	311.08	400.97	406.6
2022	**569.94**	**536.6**	**782.62**	**749.63**
2023	**338.48**	**322.24**	**447.62**	**425.75**
2024	410.74	424.61	525.27	538.54

Fonte: Elaboração própria

Tabela 11: *Desempenho nas previsões temporais*

A tabela 11 exibe os resultados para o modelo treinado apenas com dados de anos anteriores. O modelo FFT empatou com o modelo OLS pelo MAE, mas superou em 10% pelo RMSE, superando a sua eficácia em 10 anos. Entretanto, é válido ressaltar a maior concentração de melhores desempenhos em anos mais recentes, com FFT com um menor erro agora também no ano de 2020.

Previsão em 2025

O IBGE ainda não disponibilizou dados oficiais de produtividade para 2025. Entretanto, há uma outra base de dados "Tabela 6588 - Série histórica da estimativa anual da área plantada, área colhida, produção e rendimento médio dos produtos das lavouras"também do IBGE, 2025b que consiste na estimativa da produtividade por estado. A última atualização foi em 13 de outubro de 2025 e será utilizada para análise de desempenho da previsão para 2025.

	PROD ESTIMADA			DIFERENÇA	
UF	FFT	OLS	IBGE	FFT	OLS
BA	3810.74	3837.81	4015.0	204.26	177.19
DF	3875.21	3859.89	3780.0	-95.21	-79.89
GO	3701.39	3707.46	3974.0	272.61	266.54
MA	**3397.04**	**3403.7**	**3209.0**	**-188.04**	**-194.7**
MG	3671.0	3671.89	3860.0	189.0	188.11
MS	3456.2	3436.13	3077.0	-379.2	-359.13
MT	**3796.97**	**3776.97**	**3923.0**	**126.03**	**146.03**
PA	3524.33	3495.61	3341.0	-183.33	-154.61
PI	**3616.87**	**3636.49**	**3361.0**	**-255.87**	**-275.49**
PR	**3637.95**	**3630.8**	**3656.0**	**18.05**	**25.2**
RO	**3780.22**	**3709.88**	**3754.0**	**-26.22**	**44.12**
RR	**3383.08**	**3114.36**	**3577.0**	**193.92**	**462.64**
RS	**3364.89**	**3402.79**	**2010.0**	**-1354.89**	**-1392.79**
SC	**3499.37**	**3419.65**	**3810.0**	**310.63**	**390.35**
SP	3553.65	3566.51	3893.0	339.35	326.49
TO	**3636.26**	**3650.66**	**3521.0**	**-115.26**	**-129.66**

Fonte: Elaboração própria

Tabela 12: *Erro por estado na estimativa para 2025*

MAE		RMSE	
OLS	FFT	OLS	FFT
296.76	**272.84**	**427.53**	**403.79**

Fonte: Elaboração própria

Tabela 13: *Erro na previsão de 2025*

Como exibido na tabela 13, o modelo com as transformadas supera o OLS em nove dos dezesseis estados (56,25%). O MAE do modelo FFT é o menor do histórico de previsões, enquanto para o RMSE é o terceiro menor.

Conclusões

Conforme o clima apresenta mudanças em seu comportamento, as técnicas de modelagem que dependem dele devem também continuar evoluindo. Esse trabalho teve por objetivo avaliar o impacto da flexibilização gerada em um modelo de regressão quadrática OLS com a inclusão das transformadas de Fourier sobre o NDVI, utilizando um histórico de produtividade de 19 anos em 1000 municípios produtores de soja em 16 diferentes estados do Brasil.

A inclusão se mostrou eficiente, de forma que o modelo FFT se sobressaiu ao OLS tanto na análise estatística, por teste de hipótese, descartando a hipótese nula de insignificância dos termos das transformadas, como na comparação de erros MAE e RMSE em predições e previsões realizadas em todo o histórico de dados, de forma temporal, seccional e em painel.

Além disso, o próprio NDVI foi exibido com extrema relevância em ambos os modelos. De princípio, o NDVI, nos meses de dezembro a fevereiro, apresentou as três maiores correlações diretas com a produtividade de soja. Posteriormente, três das seis variáveis de NDVI apresentaram significância estatística ao nível de 1%, isto é, seus intervalos de confiança de 99% não incluem zero - os mesmos meses da correlação: dezembro, janeiro e fevereiro, com NDVI em janeiro tendo a segunda maior elasticidade mediana, perdendo apenas para temperatura em dezembro.

Tanto o efeito fixo de estado como o efeito de tendência anual apresentaram significância estatística ao nível de 1%, sendo, assim, importantes inclusões em uma regressão para a produtividade de soja. As variáveis de maior destaque pelas medianas de suas elasticidades medianas - analisando em escala estadual - foram temperatura em dezembro e janeiro, precipitação em dezembro, janeiro e fevereiro e NDVI em dezembro, janeiro e fevereiro, deixando explícito como o período de dezembro a fevereiro, usualmente de floração, enchimento e maturação dos grãos, é crítico para o sucesso da plantação da cultura.

O uso de variáveis de satélite possibilitou a ampla dispersão de dados climáticos nos modelos, uma vez que temperatura tinha uma resolução de 0,25° x 0,25° e precipitação e NDVI de 0,05° x 0,05°. Sua implementação não é trivial e depende de certo poder computacional (devido à tamanha disponibilidade de pontos), entretanto, possibilita um painel completo e com extrema precisão para qualquer município coberto pelos produtos de satélites. Adicionalmente, esse tipo de dado é o utilizado pelo mercado securitário, possibilitando que as interpretações do trabalho sejam, assim, generalizadas para o contexto corporativo.

Em uma aplicação em seguros paramétricos, por exemplo, em que usualmente se utiliza apenas uma variável, a contribuição do trabalho mora na identificação estatística

de um período crítico a ser trabalhado e na relevância de cada variável. Utilizar o modelo em si como gerador de gatilho seria inviável, pois a regressão em OLS tende à média, enquanto seguros paramétricos buscam identificar *outliers* - chuvas tão excessivas que provavelmente acarretarão em perda de safra, por exemplo.

Quando realizada a previsão para 2025, o modelo FFT superou o OLS tanto no MAE, como no RMSE, mostrando ainda o menor MAE e o terceiro menor RMSE do histórico de previsões. Vale ressaltar que o comparativo foi feito com a base de estimativas por estado do IBGE e, então, está sujeito a divergências, entretanto, os valores estimados foram atualizados em outubro deste ano (2025) e mostram estabilidade (meses anteriores com valores similares).

Uma limitação relevante do trabalho refere-se ao trabalho na estrutura de dados em painel, que, embora as observações estejam organizadas por município e ano, as análises são relativas aos estados. Assim, não foram exploradas técnicas específicas para capturar a heterogeneidade não observada entre os municípios. Não explorar essas técnicas pode resultar em viés nos coeficientes, caso características atemporais dessa granularidade estejam correlacionadas com as variáveis climáticas utilizadas no modelo.

Em suma, a inclusão das variáveis de NDVI e suas transformadas foi revelada como de extrema significância estatística, melhorando a performance em relação ao modelo OLS em todas as métricas avaliadas. Além disso, a inclusão das transformadas apontou um maior controle para grandes erros na predição em painel e melhorou o desempenho da predição em até 1,94% (aproximadamente R$ 141,33 por hectare). Por fim, como se trata de um modelo que utiliza anos anteriores para a previsão, a cada ano que passa, o modelo estará em constante evolução; basta alimentá-lo com os novos dados.

Referências

[Angrist e Krueger 1991] Joshua D. Angrist e Alan B. Krueger. "Does compulsory school attendance affect schooling and earnings?" *The Quarterly Journal of Economics* 106.4 (nov. de 1991), pp. 979–1014. doi: 10.2307/2937954. url: https://doi.org/10.2307/2937954 (citado na pg. 11).

[Ashraf e Nawaz 2015] M. Ashraf e R. Nawaz. "A comparison of change detection analyses using different band algebras for baraila wetland with nasa's multitemporal landsat dataset". *Journal of Geographic Information System* 7 (2015), pp. 1–19. doi: 10.4236/jgis.2015.71001 (citado na pg. 2).

[E. D. Assad e M. L. R. C. L. Assad 2024] Eduardo Delgado Assad e Maria Leonor Ribeiro Casimiro Lopes Assad. "Mudanças do clima e agropecuária: impactos, mitigação e adaptação. desafios e oportunidades". *Estudos Avançados* 38.112 (2024), pp. 271–292. doi: 10.1590/s0103-4014.202438112.015. url: https://doi.org/10.1590/s0103-4014.202438112.015 (citado na pg. 1).

[CEPEA – Centro de Estudos Avançados em Economia Aplicada 2025] CEPEA – Centro de Estudos Avançados em Economia Aplicada. *Indicador da Soja CEPEA/ESALQ*. https://www.cepea.org.br/br/indicador/soja.aspx. Acessado em: 18 set. 2025. 2025 (citado nas pgs. 1, 24).

[Companhia Nacional de Abastecimento (CONAB) 2025] Companhia Nacional de Abastecimento (CONAB). *Séries Históricas de Safras — CONAB*. https://www.gov.br/conab/pt-br/atuacao/informacoes-agropecuarias/safras/series-historicas/. Acesso em: 18 set. 2025. 2025 (citado na pg. 1).

[Confederação da Agricultura e Pecuária do Brasil (CNA) 2025] Confederação da Agricultura e Pecuária do Brasil (CNA). *PIB do agronegócio fecha 2024 com crescimento de 1,81%*. https://www.cnabrasil.org.br/noticias/pib-do-agronegocio-fecha-2024-com-crescimento-de-1-81. Publicado em 09 abr 2025. Acesso em 18 set 2025. 2025 (citado na pg. 1).

[Cooper *et al.* 2017] Joseph Cooper, A. Nam Tran e Steven Wallander. "Testing for specification bias with a flexible fourier transform model for crop yields". *American Journal of Agricultural Economics* 99.3 (2017), pp. 800–817. doi: 10.1093/ajae/aaw084 (citado na pg. 3).

[Copernicus Climate Change Service (C3S) 2024] Copernicus Climate Change Service (C3S). *ERA5 post-processed daily-statistics on single levels from 1940 to present*. Climate Data Store (CDS). Accessed on DD-MMM-YYYY. 2024. DOI: 10.24381/cds.4991cf48 (citado na pg. 8).

[Copernicus Climate Change Service (C3S) 2025] Copernicus Climate Change Service (C3S). *June 2025 was the third-warmest June globally, with heatwaves across Europe and temperature extremes worldwide*. https://climate.copernicus.eu/copernicus-third-warmest-june-globally-heatwaves-europe-amid-temperature-extremes-across-both. Acesso em: 2025-11-19. 2025 (citado na pg. 1).

[Didan 2021] K. Didan. *MODIS/Terra Vegetation Indices Monthly L3 Global 0.05Deg CMG V061*. NASA Land Processes Distributed Active Archive Center. Data set. Date Accessed: 2025-11-17. 2021. DOI: 10.5067/MODIS/MOD13C2.061. URL: https://doi.org/10.5067/MODIS/MOD13C2.061 (citado na pg. 9).

[Fenton e Gallant 1996] Victor M. Fenton e A. Ronald Gallant. "Qualitative and asymptotic performance of snp density estimators". *Journal of Econometrics* 74.1 (1996), pp. 77–118. ISSN: 0304-4076. DOI: 10.1016/0304-4076(95)01752-6. URL: https://www.sciencedirect.com/science/article/pii/0304407695017526 (citado na pg. 13).

[Ferreira *et al.* 2024] R. C. Ferreira, R. N. R. Sibaldelli, L. G. T. Crusiol, N. Neumaier e J. R. B. Farias. "Soybean yield losses related to drought events in brazil: spatial–temporal trends over five decades and management strategies". *Agriculture* 14.12 (2024), p. 2144. DOI: 10.3390/agriculture14122144. URL: https://doi.org/10.3390/agriculture14122144 (citado na pg. 1).

[Funk *et al.* 2014] C. C. Funk *et al. A quasi-global precipitation time series for drought monitoring*. 2014. URL: ftp://ftp.chc.ucsb/pub/org/chg/products/CHIRPS-2.0/docs/USGS-DS832.CHIRPS.pdf (citado na pg. 8).

[Gallant 1981] A. Ronald Gallant. "On the bias in flexible functional forms and an essentially unbiased form: the fourier flexible form". *Journal of Econometrics* 15.2 (1981), pp. 211–245. ISSN: 0304-4076. DOI: 10.1016/0304-4076(81)90115-9 (citado na pg. 3).

[Gasparetto 2024] Suelen Cristina Gasparetto. "Precificação do risco agrícola: abordagens para o seguro agrícola de produtividade e de receita". Acesso em: 2025-11-19. Tese (Doutorado em Estatística e Experimentação Agronômica). Piracicaba: Escola Superior de Agricultura Luiz de Queiroz, Universidade de São Paulo, 2024. DOI: 10.11606/T.11.2024.tde-07102024-092119 (citado na pg. 3).

[Gelman e Hill 2006] Andrew Gelman e Jennifer Hill. "Analysis of variance". In: *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press, 2006, pp. 487–502. DOI: 10.1017/CBO9780511790942.028. URL: https://doi.org/10.1017/CBO9780511790942.028 (citado na pg. 23).

[IBGE 2025a] IBGE. *SIDRA – Sistema IBGE de Recuperação Automática: Tabela 5457 – Área plantada, área colhida e quantidade produzida na lavoura temporária, por produto*. https://sidra.ibge.gov.br/tabela/5457. Acesso em: 18 nov. 2025. 2025 (citado na pg. 7).

[IBGE 2025b] IBGE. *SIDRA – Sistema IBGE de Recuperação Automática: Tabela 6588*. https://sidra.ibge.gov.br/tabela/6588. Acesso em: 18 nov. 2025. 2025 (citado na pg. 27).

[Instituto Nacional de Meteorologia (INMET) s.d.] Instituto Nacional de Meteorologia (INMET). *Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP)*. INMET. Disponível em: https://bdmep.inmet.gov.br/. Acesso em: 15/10/2025 (citado na pg. 9).

[Miot 2018] H. A. Miot. "Correlation analysis in clinical and experimental studies". *J Vasc Bras* 17.4 (out. de 2018), pp. 275–279. doi: 10.1590/1677-5449.174118 (citado nas pgs. 15, 16).

[Muminov *et al.* 2016] Mahmud A. Muminov *et al.* "Monitoring vegetation coverage and biomass using landsat thematic mapper 5 images in a foothill artemisia-ephemeral rangeland of uzbekistan". *Open Journal of Ecology* 6.12 (2016). Accessed: 2025-11-19, pp. 736–752. doi: 10.4236/oje.2016.612066. url: https://www.scirp.org/journal/paperinformation?paperid=72342 (citado na pg. 2).

[Wang *et al.* 2023] Qi Wang, Chang Xu e Tieyan Zhou. "Stock price prediction based on multiple linear regression". *BCP Business & Management* 36 (2023), pp. 48–54. doi: 10.54691/bcpbm.v36i.3384 (citado na pg. 11).

[Xu e Katchova 2019] Chang Xu e Ani L. Katchova. "Predicting soybean yield with ndvi using a flexible fourier transform model". *Journal of Agricultural and Applied Economics* 51.3 (mai. de 2019), pp. 402–416. doi: 10.1017/aae.2019.5 (citado nas pgs. 2, 3, 13).